



USMP

UNIVERSIDAD DE
SAN MARTÍN DE PORRES

**FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA DE COMPUTACIÓN Y SISTEMAS**

**SISTEMA BASADO EN MACHINE LEARNING E IA GENERATIVA
PARA OPTIMIZAR LA GESTIÓN COMERCIAL EN INDUSTRIAS
JHOMERON S.A.**

ASIGNATURA

PROYECTO FINAL DE INGENIERÍA DE COMPUTACIÓN Y SISTEMAS

PRESENTADO POR:

JUAN MARCIAL TORVISCO RIOS

JEAN PIERRE ANTHONY LOBATON OCHOA

ASESOR:

Dr. JORGE MARTIN FIGUEROA REVILLA

ORCID ID: 0000-0003-0884-2571

LÍNEA DE INVESTIGACIÓN:

**DESARROLLO TECNOLÓGICO, INTELIGENCIA ARTIFICIAL E
INFRAESTRUCTURAS SOSTENIBLES**

LIMA, PERÚ

2026

ÍNDICE

CAPÍTULO I	PLANTEAMIENTO DEL PROBLEMA	6
1.1.	Descripción de la situación problemática.....	6
1.2.	Formulación del problema.....	8
1.3.	Objetivos de la investigación.....	9
1.4.	Justificación de la investigación.....	10
1.4.1.	Importancia de la investigación	10
1.4.2.	Viabilidad de la investigación	11
CAPÍTULO II	MARCO TEÓRICO	13
2.1.	Antecedentes de la investigación.....	13
2.2.	Bases teóricas	18
2.3.	Definición de términos básicos	24
CAPÍTULO III	PROPUESTA DEL SISTEMA BASADO EN MACHINE LEARNING E IA GENERATIVA PARA OPTIMIZAR LA GESTIÓN COMERCIAL	
	26	
3.1.	Propuesta del sistema	26
3.2.	Variables y definición operacional.....	29
CAPÍTULO IV	METODOLOGÍA.....	33
4.1.	Diseño Metodológico	33
4.2.	Técnicas de recolección de datos	35
4.3.	Técnicas estadísticas para el procesamiento de la información	36
4.4.	Diseño muestral	37

4.5. Aspectos éticos	38
CRONOGRAMA.....	40
FUENTES DE INFORMACIÓN	41
ANEXOS.....	44

ÍNDICE DE FIGURAS

Figura 1 Diagrama de Gantt.....	40
--	----

ÍNDICE DE TABLAS

Tabla 1 Tabla de Variable Independiente de Dimensiones e Indicadores.....30

Tabla 2 Tabla de Variable Dependiente de Dimensiones e Indicadores32

1.1. Descripción de la situación problemática

La gestión comercial en empresas manufactureras enfrenta actualmente una limitación estructural, aunque la información necesaria para la toma de decisiones de venta se encuentra almacenada en los sistemas internos de la organización, esta no está disponible en el momento oportuno ni en el formato adecuado para su uso operativo. Diversos estudios han evidenciado que la subutilización de datos comerciales genera pérdidas directas de oportunidades de venta, mientras que las empresas que logran capitalizar su información histórica incrementan sus ingresos de forma significativa (Fang et al., 2026). Esta desconexión entre la disponibilidad de datos y su aprovechamiento efectivo en la operación comercial constituye el problema central identificado en Industrias Jhomeron S.A.

Industrias Jhomeron S.A. es una compañía peruana dedicada a la producción y venta de pinturas látex, esmaltes, masillas, diluyentes y resinas, que tiene su fuerza de ventas repartida entre Lima y varias zonas del país. La compañía lleva un registro de sus operaciones comerciales en el sistema SAP Business One para la planificación de recursos empresariales, que conserva un extenso historial de transacciones por cliente, producto y área geográfica. No obstante, esa información no se convierte en saber útil para las partes implicadas en la toma de decisiones de negocios.

Esta problemática se manifiesta en dos dimensiones principales. En primer lugar, desde la perspectiva de los vendedores, se evidencia la

ausencia de herramientas que permitan convertir el historial de ventas en información accionable durante la interacción con el cliente. Actualmente, los vendedores cuentan con un sitio web y catálogos físicos y digitales compartidos por WhatsApp como recursos de consulta; ninguno les permite acceder a información personalizada del cliente, precios actualizados ni escala de precios por volumen vigente. Esta limitación reduce la efectividad del proceso de venta y dificulta la personalización de la oferta comercial (Jarotschkin et al., 2025). Asimismo, ante cualquier consulta específica, deben comunicarse con la jefa de ventas o gerencia por llamada o WhatsApp, lo que genera retrasos e interrupciones durante la atención al cliente. Esta situación es especialmente crítica para los vendedores de provincias, quienes además enfrentan con frecuencia canales ocupados o la imposibilidad de realizar una consulta mientras el cliente está presente, y cuyo único contacto presencial con la gerencia ocurre una vez al mes cuando se trasladan a Lima por tres a cinco días. La literatura identifica la ausencia de herramientas conversacionales como una barrera crítica en entornos comerciales distribuidos (Poniszewska-Maranda et al., 2025). El proceso actual del vendedor se detalla en el **Anexo 1**.

En segundo lugar, desde la perspectiva gerencial, el análisis de la información comercial depende en gran medida de procesos manuales. La generación de reportes implica la extracción de datos desde SAP Business One hacia hojas de cálculo y su posterior procesamiento, lo que introduce demoras y limita la capacidad de respuesta ante requerimientos analíticos. Esta situación refleja una problemática común en empresas

medianas, donde los usuarios no técnicos enfrentan dificultades para acceder de manera autónoma a información analítica, afectando la agilidad en la toma de decisiones (Liu et al., 2025). El proceso actual de la gerencia se detalla en el **Anexo 2**.

En conclusión, las limitaciones identificadas reflejan una deficiente explotación de los datos disponibles para la gestión comercial. La ausencia de mecanismos que permitan convertir el historial de ventas en conocimiento útil y oportuno restringe la toma de decisiones estratégicas y disminuye la capacidad de respuesta ante oportunidades del mercado. En este contexto, surge la necesidad de incorporar herramientas tecnológicas que faciliten el acceso y análisis de estos datos, contribuyendo a mejorar el desempeño organizacional y la generación de valor para la empresa.

1.2. Formulación del problema

Problema General

¿De qué manera un sistema basado en Machine Learning e inteligencia artificial generativa optimiza la gestión comercial de Industrias Jhomeron S.A.?

Problemas Específicos

- a) ¿En qué medida un módulo basado en Machine Learning e inteligencia artificial generativa mejora la capacidad de los vendedores para consultar información comercial en campo y fortalecer la atención al cliente mediante el análisis del historial de compras?

- b) ¿De qué forma un módulo de análisis conversacional basado en inteligencia artificial generativa reduce el tiempo de acceso a información comercial por parte de la gerencia?
- c) ¿En qué medida el sistema propuesto mejora la toma de decisiones comerciales en Industrias Jhomeron S.A. a partir de la identificación de patrones de comportamiento de compra?

1.3. Objetivos de la investigación

Objetivo General

Diseñar y validar un sistema basado en Machine Learning e inteligencia artificial generativa que optimice la gestión comercial en Industrias Jhomeron S.A.

Objetivos Específicos

- a) Diseñar un módulo inteligente de apoyo comercial basado en inteligencia artificial generativa y Machine Learning que permita a los vendedores consultar información comercial mediante lenguaje natural y generar análisis del historial de compras del cliente, con el propósito de optimizar la atención en campo y fortalecer la toma de decisiones durante el proceso de venta.
- b) Desarrollar un módulo de análisis conversacional basado en inteligencia artificial generativa que permita a la gerencia acceder a información analítica actualizada mediante lenguaje natural.
- c) Evaluar el impacto del sistema en la detección de patrones de compra y en la mejora de la toma de decisiones comerciales en Industrias Jhomeron S.A.

1.4. Justificación de la investigación

1.4.1. Importancia de la investigación

La presente investigación es relevante porque propone el desarrollo de un sistema basado en Machine Learning e inteligencia artificial generativa orientado a mejorar la gestión comercial en Industrias Jhomerón S.A., mediante el aprovechamiento de su información histórica de ventas.

En este sentido, el principal resultado esperado es la obtención de un sistema que permita transformar los datos comerciales en información útil y accesible, actualizada mediante procesos batch automatizados, facilitando tanto el apoyo operativo a los vendedores en campo como el análisis conversacional de información para la toma de decisiones de la gerencia.

La relevancia de la investigación radica en que aborda una problemática frecuente en empresas manufactureras medianas, donde, a pesar de contar con grandes volúmenes de datos, estos no son utilizados de manera efectiva en los procesos comerciales. Diversos estudios han demostrado que el uso de inteligencia artificial en entornos comerciales incrementa significativamente el desempeño en ventas y la eficiencia operativa (Le Dinh et al., 2025).

Los principales beneficios del sistema se centran en la mejora de la eficiencia comercial, la reducción de tiempos de acceso a la información y el incremento en la capacidad de análisis de datos. Para los vendedores en campo, el beneficio más inmediato es consultar precios, escala de precios por volumen y características de productos de forma autónoma

desde su celular, sin interrumpir la atención al cliente, además de contar con un análisis del historial de compras de cada cliente asignado que le permite identificar qué productos ofrecerle. Para la gerencia, implica acceder a información analítica mediante consultas en lenguaje natural, reduciendo la dependencia de procesos manuales y mejorando la agilidad en la toma de decisiones tanto a nivel operativo como estratégico (Jiang et al., 2025).

Los beneficiarios directos son los vendedores de campo, el personal de atención comercial y la gerencia de Industrias Jhomeron S.A. Estudios previos han evidenciado que la implementación de sistemas inteligentes genera mejoras significativas en la productividad comercial (Singh et al., 2024).

1.4.2. Viabilidad de la investigación

La presente investigación es viable, ya que se cuenta con los recursos técnicos, humanos, materiales y de acceso a la información necesarios para su desarrollo dentro del plazo establecido.

Desde el punto de vista técnico, Industrias Jhomeron S.A. dispone del sistema de planificación de recursos empresariales SAP Business One, cuya base de datos opera sobre SAP HANA. Esta plataforma registra de manera estructurada el historial de transacciones comerciales, constituyendo el insumo principal para el desarrollo del sistema. A partir de esta fuente, se construye un DataMart propio del sistema que organiza y centraliza los datos necesarios para los módulos propuestos, el cual es alimentado mediante un proceso de extracción, transformación y carga

implementado con Spring Batch. La literatura destaca que la disponibilidad de datos históricos de calidad y la alineación estratégica son factores clave en proyectos de aprendizaje automático en organizaciones (Mirkovski et al., 2025).

En cuanto a la viabilidad operativa, se cuenta con acceso autorizado a la información y con la disposición de la gerencia para participar en la validación del sistema. Asimismo, los usuarios podrán acceder mediante interfaces web desde dispositivos móviles o computadoras, facilitando su uso en el entorno organizacional.

Respecto a los recursos humanos, el equipo de investigación dispone de conocimientos en aprendizaje automático, procesamiento de lenguaje natural e integración de sistemas, necesarios para el desarrollo de la solución. En cuanto a los recursos materiales y tecnológicos, se emplearán herramientas de código abierto desplegadas en la infraestructura On-Premise de Industrias Jhomeron S.A., complementadas con servicios en nube para componentes específicos, lo que garantiza la viabilidad económica del proyecto. El análisis económico del sistema, incluyendo los costos operativos mensuales y la viabilidad financiera con VAN y TIR estimados, se presenta en el **Anexo 3**. El detalle de la arquitectura tecnológica propuesta y componentes del sistema se presenta en el **Anexo 4**. Finalmente, en cuanto a la viabilidad temporal, el proyecto se ejecutará dentro del período académico establecido, considerando las fases de diseño, desarrollo, implementación y validación. En conjunto, estos aspectos evidencian que la investigación es factible en términos técnicos, operativos y económicos.

CAPÍTULO II

MARCO TEÓRICO

2.1. Antecedentes de la investigación

Según Fang et al. (2026), realizaron el estudio Generative AI and Firm Productivity: Field Experiments in Online Retail, su objetivo fue cuantificar el impacto de la inteligencia artificial generativa en la productividad empresarial mediante experimentos de campo a gran escala con millones de usuarios. Utilizaron metodología experimental aleatorizada evaluando siete flujos de trabajo comerciales entre 2023 y 2024. Obtuvieron como resultado que la adopción de inteligencia artificial generativa incrementa las ventas entre 0 % y 16.3 %, con mejoras directas en productividad total. Este antecedente aporta a la presente investigación porque demuestra con datos reales de campo que los sistemas de inteligencia artificial generativa aplicados a procesos comerciales generan impacto económico medible, validando la pertinencia del sistema propuesto para Industrias Jhomeron S.A.

Según Singh et al. (2024), realizaron el estudio A Case Study of Generative AI in MSX Sales Copilot: Improving Seller Productivity with a Real-Time Question-Answering System for Content Recommendation, su objetivo fue elaborar y poner en marcha un sistema de recomendaciones en tiempo real, fundamentado en inteligencia artificial generativa, para ayudar a los vendedores durante la atención al cliente. Se empleó una arquitectura de doble codificador con re-ranker implementada en el sistema de gestión comercial Dynamics CRM de Microsoft. Como resultado, desarrollaron un sistema que puede proporcionar sugerencias pertinentes en cuestión de segundos para amplios catálogos, el cual es utilizado cotidianamente por vendedores reales en producción. Este

antecedente contribuye de manera directa a la investigación actual, ya que documenta con precisión el enfoque sugerido y valida su viabilidad en un entorno empresarial real comparable al de Industrias Jhomeron S.A. Según Jiang et al. (2025), desarrollaron SiriusBI: A Comprehensive LLM-Powered Solution for Data Analytics in Business Intelligence, su objetivo fue crear una solución que utilizara grandes modelos de lenguaje para realizar consultas a bases de datos corporativas en lengua natural. Con un método experimental y módulos de diálogo multi-ronda, consiguieron una exactitud superior al 93 % en la creación de consultas. En áreas de publicidad, finanzas y nube, lograron disminuir el tiempo de consulta, pasando de minutos a segundos. Este antecedente contribuye a la investigación actual como un referente técnico directo del módulo de inteligencia artificial generativa que se sugiere para que el equipo gerencial de Industrias Jhomeron S.A. pueda consultar su sistema en lenguaje natural.

Según Jarotschkin et al. (2025), publicaron Artificial Intelligence in Sales Research: Identifying Emergent Themes and Looking Forward, su objetivo fue detectar las temáticas emergentes en la investigación de inteligencia artificial aplicada a ventas. Emplearon análisis bibliométrico con revisión sistemática. Llegaron a la conclusión de que el aprendizaje automático ayuda a optimizar las decisiones de venta personal, con pruebas de que los vendedores respaldados por inteligencia artificial tienen 3.7 veces más probabilidad de cumplir sus objetivos. Este antecedente ofrece información porque muestra de manera directa el efecto que tiene el aprendizaje automático en los equipos de ventas, lo cual apoya la

importancia del módulo sugerido para los vendedores de Industrias Jhomeron S.A.

Según Gangadharan et al. (2024), publicaron *From Data to Decisions: The Transformational Power of Machine Learning in Business Recommendations*, su objetivo fue analizar el rol del aprendizaje automático en sistemas de recomendación comercial, enfocándose en ingeniería de características y métricas de evaluación. Utilizaron revisión de literatura con énfasis en aplicaciones empresariales reales. Obtuvieron que los sistemas de recomendación contribuyen significativamente a las ventas y la ventaja competitiva de las empresas. Este antecedente es útil porque documenta el efecto mensurable que tienen los sistemas de recomendación de aprendizaje automático en los resultados comerciales.

Según Boustani et al. (2024), publicaron *Improving the Predictive Accuracy of the Cross-Selling of Consumer Loans Using Deep Learning Networks*, en *Annals of Operations Research*, su objetivo fue mejorar los modelos de venta cruzada usando datos de transacciones históricas y aprendizaje profundo. Utilizaron un autoencoder extrayendo características de casi 800,000 transacciones reales. Obtuvieron que se descubrió que los datos de las transacciones incluyen información útil sobre el comportamiento de compra, lo cual mejora la exactitud de los modelos de venta cruzada. Este antecedente es útil porque respalda el empleo de datos históricos de operaciones para optimizar la recomendación de venta cruzada, que es precisamente la perspectiva del módulo sugerido.

Según Mirkovski et al. (2025), publicaron An AI-Assisted Framework for Improving Innovativeness in Small Businesses: A Human–AI Collaboration Perspective, su objetivo fue presentar un marco de cooperación entre humanos e inteligencia artificial con el fin de optimizar la capacidad innovadora en pequeñas empresas a través del empleo de herramientas de inteligencia artificial. Emplearon un método de diseño conceptual que se apoya en ejemplos de aplicación en pequeñas empresas de diversas industrias. Como resultado, hallaron que la incorporación de herramientas de inteligencia artificial en los procedimientos operativos de las pequeñas empresas mejora considerablemente su habilidad para innovar, tomar decisiones y ser competitivas. Este precedente contribuye a la investigación actual al registrar los elementos que permiten que las empresas de dimensiones parecidas a las de Industrias Jhomerón S.A. adopten con éxito la inteligencia artificial, lo cual fortalece la viabilidad del sistema propuesto.

Según Chambi Condori (2023), publicó el artículo Segmentación de mercado: Machine Learning en marketing en contextos de covid-19, Su propósito fue implementar el modelo de agrupamiento con herramientas de aprendizaje automático, para dividir a los clientes en segmentos, lo cual es un elemento fundamental de la administración del marketing corporativo. Utilizó metodología cuantitativa con algoritmos de clustering implementados en RapidMiner, evaluando el rendimiento mediante el índice Davies-Bouldin para determinar el número óptimo de segmentos de clientes. Obtuvo como resultado la identificación de segmentos diferenciados de consumidores con patrones de comportamiento de

compra distintos, demostrando que el Machine Learning permite tomar decisiones comerciales más precisas y personalizadas. Este antecedente es relevante para el presente estudio, ya que enmarca dentro del contexto peruano la implementación de Machine Learning para detectar patrones de conducta de compra de los clientes, lo cual apoya el módulo de apoyo comercial propuesto para Industrias Jhomeron S.A.

Según Suárez Romero (2024), realizó la investigación Modelo Deep Learning para mejorar la predicción de las ventas en la Empresa San Fernando S.A.C., Lima, 2023, presentada como tesis de pregrado en la Universidad Nacional Federico Villarreal, Lima, Perú. Su objetivo fue crear un modelo de redes neuronales profundas con el fin de optimizar la proyección de ventas y respaldar la decisión comercial. Empleó un enfoque experimental que aplicaba un modelo de Deep Learning sobre información histórica de ventas del 2023, utilizando herramientas para evaluar el desempeño del modelo y los registros de ventas de la base de datos corporativa. Logró una mejora notable en la exactitud de las estimaciones de ventas, lo que tiene un impacto directo en la administración de recursos y la planificación comercial. Este antecedente contribuye a la investigación actual al mostrar que los modelos de aprendizaje automático aplicados a datos históricos de ventas de compañías peruanas producen resultados predictivos confiables, lo cual apoya el módulo de recomendación sugerido.

Según Flores Poemape y Flores Sulca (2025), realizaron la investigación Machine learning para la gestión de ventas en una empresa del sector tecnológico, su objetivo fue analizar cómo el empleo de métodos de

Machine Learning afecta la eficiencia y la productividad en el manejo de ventas de una compañía peruana dedicada a la tecnología. Siguiendo el método CRISP-DM, emplearon una metodología aplicada de diseño preexperimental con pretest y posttest, así como un enfoque cuantitativo. Para ello, aplicaron los algoritmos XGBoost, regresión lineal y Random Forest a una muestra de 12 meses de datos de ventas. La eficiencia y la productividad se incrementaron de manera estadísticamente significativa, la primera pasó de 77.50 % a 83.08 % y la segunda, de 67.08 % a 69.00 %, según lo corroborado con la prueba T para muestras emparejadas con $p < 0.001$. Este antecedente es relevante para la investigación actual, ya que respalda el uso de Random Forest y XGBoost en la administración de ventas de una compañía peruana, lo que confirma la selección de estos algoritmos para el módulo de recomendación diseñado para Industrias Jhomeron S.A.

2.2. Bases teóricas

2.2.1. Machine Learning aplicado a sistemas de recomendación comercial

El Machine Learning, una subdisciplina de la inteligencia artificial, se enfoca en el desarrollo de modelos que puedan aprender patrones a partir de datos históricos y hacer predicciones sin necesidad de ser programados explícitamente. En el sector comercial, su utilización posibilita el análisis de la conducta de compra de los consumidores y la conversión de enormes cantidades de datos transaccionales en sugerencias personalizadas, lo que ayuda a optimizar la eficacia de las tácticas comerciales.

Las técnicas de recomendación que se basan en el aprendizaje automático se dividen, ante todo, en tres métodos: filtrado colaborativo, filtrado basado en contenido y modelos híbridos. El filtrado colaborativo, por un lado, se centra en las similitudes entre los clientes para deducir sus preferencias; el filtrado basado en contenido, por otro lado, se enfoca en las características de los productos que han sido comprados con anterioridad. No obstante, según la literatura más reciente, los métodos híbridos posibilitan sobrepasar las restricciones individuales de cada técnica, alcanzando una mayor precisión y robustez en contextos comerciales intrincados (Gangadharan et al., 2024).

Además, se ha demostrado que algoritmos de conjunto como XGBoost y Random Forest tienen un mejor rendimiento en situaciones de recomendación porque pueden modelar relaciones no lineales y gestionar datos diversos (Loukili et al., 2024). En este marco, el estudio actual emplea una perspectiva híbrida fundamentada en Machine Learning, con la finalidad de identificar patrones de compra del cliente que apoyen al vendedor durante la atención en campo en Industrias Jhomeron S.A.

2.2.2. Inteligencia artificial generativa y consulta en lenguaje natural

La inteligencia artificial generativa, especialmente por medio de modelos de lenguaje amplios, ha posibilitado la creación de sistemas que pueden entender y producir texto en lenguaje natural, lo cual favorece el intercambio entre los usuarios y los sistemas de información. Una de sus aplicaciones más importantes en contextos empresariales consiste en traducir preguntas formuladas en lenguaje natural a operaciones

estructuradas sobre bases de datos, lo que elimina la necesidad de conocimiento técnico para acceder a la información.

Este enfoque, conocido como Natural Language to SQL, permite que preguntas como “¿qué clientes compraron un producto específico en un periodo determinado?” sean convertidas automáticamente en consultas ejecutables, reduciendo significativamente los tiempos de acceso a la información (Jiang et al., 2025). Asimismo, diversos estudios han demostrado que estos sistemas incrementan la productividad en tareas de análisis de datos y recuperación de información (Peng et al., 2024).

Por otra parte, estudios recientes muestran que la integración de inteligencia artificial generativa con sistemas de recomendación mejora la adaptabilidad y la capacidad de respuesta de los sistemas comerciales, lo cual supera a métodos convencionales (Liang & Zhang, 2025).

En este sentido, la presente investigación incorpora inteligencia artificial generativa como interfaz conversacional, implementada mediante Claude 3 de Anthropic, accedido a través de Amazon Bedrock, permitiendo a vendedores y gerencia consultar información comercial en datos históricos actualizados mediante lenguaje natural, facilitando el acceso a la información y reduciendo la dependencia de los procedimientos manuales.

2.2.3. Sistemas de planificación de recursos empresariales como fuente de datos

Los sistemas de planificación de recursos empresariales integran los principales procesos de una organización, incluyendo ventas, inventario, finanzas y producción, centralizando la información en una única plataforma. En el caso de Industrias Jhomeron S.A., el sistema utilizado es SAP Business One, cuya base de datos opera sobre SAP HANA. Esta plataforma registra de manera estructurada el historial de transacciones comerciales por cliente, producto, zona geográfica y vendedor.

La extracción de esta información hacia el sistema propuesto se realiza mediante procedimientos almacenados sobre SAP HANA, ejecutados a través de un proceso ETL implementado con Spring Batch de forma semanal. Los datos extraídos son cargados en un DataMart propio del sistema, organizado en esquema estrella, que constituye la fuente de datos central tanto para el entrenamiento de los modelos de Machine Learning como para el módulo de consulta conversacional. Adicionalmente, el sistema considera como segunda fuente de datos el archivo de precios por unidad y por volumen gestionado por la jefa de ventas, el cual contiene la escala de precios oficial por producto y es cargado al sistema como tabla de configuración actualizable. La literatura señala que contar con datos históricos de alta calidad es uno de los factores más determinantes para el éxito de proyectos de aprendizaje automático en compañías medianas (Mirkovski et al., 2025).

Igualmente, la combinación de inteligencia artificial con sistemas ERP ha evidenciado que optimiza la eficacia a nivel operativo y en la toma de decisiones corporativas (Mhaskey, 2024), lo cual enfatiza cuán relevante

es emplear estos sistemas como fundamento para crear soluciones inteligentes.

2.2.4. Gestión comercial en empresas manufactureras medianas

La gestión comercial en empresas manufactureras medianas se caracteriza por la administración de relaciones con clientes, la planificación de ventas y la ejecución de estrategias orientadas a maximizar los ingresos. En este tipo de organizaciones, los equipos comerciales suelen manejar amplias carteras de clientes distribuidos geográficamente, lo que genera una alta dependencia del conocimiento individual de los vendedores.

Esta situación limita la capacidad de estandarizar procesos de venta y dificulta el aprovechamiento de la información histórica disponible. Investigaciones recientes muestran que la inclusión de instrumentos fundamentados en inteligencia artificial facilita el aumento de la productividad de los grupos comerciales y la mejora de la toma de decisiones en contextos reales (Singh et al., 2024).

Además, la implementación de sistemas de recomendación dinámicos posibilita que las estrategias comerciales se ajusten a las variaciones en el comportamiento del consumidor, lo cual mejora la efectividad de las iniciativas de venta (Ou et al., 2025).

En esta línea, el presente estudio busca mejorar la gestión comercial mediante herramientas tecnológicas que conviertan los datos disponibles en información valiosa para vendedores y gerencia, reduciendo la

dependencia del conocimiento empírico. Para ello, se utiliza el sistema ERP de la empresa como fuente principal de datos, permitiendo entrenar modelos de Machine Learning para el análisis de patrones de compra y alimentar el módulo de consulta conversacional.

2.2.5. Venta cruzada y sistemas de recomendación basados en historial transaccional

La venta cruzada es una técnica de ventas que implica ofrecer productos complementarios al cliente en el transcurso de la compra, con la finalidad de aumentar el valor de cada operación. Esta práctica es ampliamente utilizada en entornos comerciales debido a su impacto directo en el incremento de ingresos.

Los sistemas de recomendación que emplean aprendizaje automático permiten identificar oportunidades de venta cruzada mediante el análisis de patrones de co-ocurrencia en el historial de compras. Estos modelos detectan relaciones entre productos que frecuentemente se adquieren en conjunto, generando recomendaciones relevantes para cada cliente.

Múltiples investigaciones han evidenciado que el empleo de datos transaccionales históricos mejora significativamente la precisión de los modelos de recomendación y permite capturar el comportamiento real de los clientes (Boustani et al., 2024). Asimismo, el problema de inicio en frío, asociado a clientes sin historial previo, puede abordarse mediante el análisis de perfiles similares o características demográficas (Xu et al., 2024).

En este marco, el estudio actual emplea el análisis de datos históricos para reconocer patrones de compra del cliente que apoyen al vendedor durante la atención al cliente, ayudando así a optimizar el funcionamiento comercial de la compañía.

2.3. Definición de términos básicos

Machine Learning: Rama de la inteligencia artificial que permite a los sistemas aprender patrones a partir de datos históricos sin ser explícitamente programados. En el sistema propuesto, identifica patrones de compra de los clientes y genera análisis de comportamiento que apoyan al vendedor durante la atención en campo.

Inteligencia artificial generativa: Conjunto de modelos capaces de generar contenido nuevo como texto o consultas sobre bases de datos a partir de instrucciones en lenguaje natural. En el sistema propuesto, permite a los vendedores consultar información comercial y a la gerencia obtener análisis de ventas sin conocimientos técnicos.

Módulo de apoyo comercial: Componente del sistema orientado a los vendedores que integra consulta de información en lenguaje natural y análisis del historial de compras del cliente asignado, con el fin de apoyar la atención en campo de forma autónoma e inmediata.

Consulta en lenguaje natural a base de datos: Tecnología que convierte preguntas formuladas en lenguaje cotidiano en instrucciones ejecutables sobre bases de datos relacionales, sin necesidad de conocimientos técnicos.

Grandes modelos de lenguaje: Modelos de aprendizaje automático entrenados en vastos corpus de texto que comprenden y generan

lenguaje natural. En el sistema propuesto se utiliza Claude 3 de Anthropic, accedido mediante Amazon Bedrock, tanto para el módulo de consulta de información comercial de los vendedores como para el módulo de análisis conversacional de la gerencia, ambos mediante conversión de lenguaje natural a consultas estructuradas sobre el DataMart.

Filtrado colaborativo: Técnica de recomendación que identifica clientes con comportamientos de compra similares y sugiere productos que clientes de perfil análogo han adquirido. En el sistema propuesto se combina con el filtrado basado en contenido dentro de un enfoque híbrido implementado con XGBoost y Random Forest, con el fin de identificar patrones de compra y apoyar al vendedor durante la atención al cliente.

Filtrado basado en contenido: Técnica de recomendación que analiza las características de los productos adquiridos previamente por un cliente para sugerir productos similares. En el sistema propuesto complementa al filtrado colaborativo dentro del enfoque híbrido del módulo de apoyo comercial.

SAP Business One: Sistema de planificación de recursos empresariales utilizado por Industrias Jhomerón S.A. para la gestión de sus operaciones comerciales, cuya base de datos opera sobre SAP HANA. Constituye la fuente principal de datos históricos del sistema propuesto.

DataMart: Base de datos analítica propia del sistema, organizada en esquema estrella e implementada en PostgreSQL, que centraliza y estructura los datos históricos de ventas extraídos desde SAP HANA a través de SAP Business One mediante un proceso ETL con Spring Batch.

Constituye la fuente de datos central del sistema para el entrenamiento de modelos de Machine Learning y las consultas en lenguaje natural.

ETL (Extract, Transform, Load): Proceso automatizado que extrae datos desde una fuente de origen, los transforma para asegurar su calidad y consistencia, y los carga en un destino analítico. En el sistema propuesto, Spring Batch ejecuta este proceso semanalmente extrayendo datos desde SAP HANA y cargándolos en el DataMart del sistema.

Venta cruzada: Práctica de ofrecer al cliente productos complementarios durante la atención comercial. El sistema propuesto apoya esta práctica mediante el análisis del historial transaccional del cliente realizado por el módulo de Machine Learning.

CAPÍTULO III PROPUESTA DEL SISTEMA BASADO EN MACHINE LEARNING E IA GENERATIVA PARA OPTIMIZAR LA GESTIÓN COMERCIAL

3.1. Propuesta del sistema

La investigación actual propone una plataforma de inteligencia comercial basada en el aprendizaje automático e inteligencia artificial generativa para Industrias Jhomerón S.A., accesible desde dispositivos móviles y computadoras mediante una interfaz web ligera. El sistema aprovecha el historial transaccional registrado en SAP Business One sobre SAP HANA, centralizado en un DataMart propio del sistema, como fuente principal de datos, complementado con la tabla de precios por unidad y volumen gestionada por la jefa de ventas. La actualización de datos se realiza mediante un proceso batch semanal automatizado. La plataforma opera con autenticación por roles, de modo que cada usuario accede

únicamente a las funcionalidades de su perfil: vendedor, jefe de ventas o gerente. El sistema se distribuye en dos módulos fundamentales:

Módulo 1: Apoyo comercial para vendedores

Este módulo tiene como finalidad apoyar al vendedor durante la atención al cliente en campo, brindándole acceso inmediato a información comercial actualizada y análisis del historial de compras de sus clientes asignados.

El módulo integra dos funcionalidades complementarias. La primera es la consulta de información comercial en lenguaje natural, que permite al vendedor preguntar sobre precios, escala de precios por volumen, características, colores y usos de los productos, obteniendo respuestas inmediatas sin necesidad de llamar a la jefa de ventas. La segunda funcionalidad corresponde al análisis del historial de compras por cliente, basado en un modelo de Machine Learning que identifica patrones de compra y estima los productos con mayor probabilidad de adquisición. Este análisis puede ser solicitado por el vendedor durante la atención comercial mediante la selección del cliente asignado dentro del sistema. A partir de ello, el sistema genera recomendaciones orientadas a apoyar la venta cruzada y fortalecer la toma de decisiones durante la interacción comercial. Para clientes nuevos sin historial previo, el vendedor podrá indicar el producto de interés mediante lenguaje natural y el sistema sugerirá productos complementarios utilizando patrones de coocurrencia obtenidos del historial transaccional, reduciendo así el problema de inicio en frío.

Módulo 2: Análisis conversacional para la gerencia

Este módulo está orientado a facilitar el acceso a información analítica por parte de la gerencia y el área comercial. La propuesta es emplear inteligencia artificial generativa para posibilitar el acceso a datos en lenguaje natural, suprimiendo la necesidad de llevar a cabo procedimientos de extracción y análisis manuales.

El sistema posibilitará que la gerencia y la jefa de ventas formulen preguntas sobre el comportamiento de ventas, clientes o productos, como por ejemplo "¿cuáles fueron los productos más vendidos en Lima el último mes?", las cuales serán analizadas y transformadas automáticamente en consultas estructuradas sobre el DataMart. Los resultados se devolverán de inmediato, lo que ayudará a optimizar la rapidez en la toma de decisiones. Además, se contempla la puesta en marcha de procesos para validar las consultas con el fin de asegurar que la información producida sea coherente y disminuir así el riesgo de fallos en los resultados.

Integración de la propuesta

Ambos módulos conforman una plataforma integrada que transforma los datos históricos de ventas en información útil y accesible para los distintos actores de la organización, ya que comparten un DataMart como fuente de datos central, cuyo diseño se presenta en el **Anexo 5**. Así, se pretende hacer más eficiente el proceso de comercialización, perfeccionar la toma de decisiones y disminuir la dependencia de procedimientos manuales.

La propuesta integra el uso de tecnologías como la inteligencia artificial generativa y el aprendizaje automático para fortalecer la gestión comercial

en Industrias Jhomeron S.A., mediante el aprovechamiento eficiente de los datos disponibles. El **Anexo 6** y el **Anexo 7** contienen los procesos sugeridos para el vendedor y la gerencia, respectivamente. Además, el **Anexo 8** contiene el artículo científico desarrollado en esta investigación. El diseño de interfaces del sistema se presenta en el **Anexo 9**.

3.2. Variables y definición operacional

Variable independiente: Sistema basado en Machine Learning e inteligencia artificial generativa

Definición conceptual:

El sistema basado en Machine Learning e inteligencia artificial generativa se define como una plataforma informática que combina métodos de aprendizaje automático para detectar patrones en datos históricos y apoyar la toma de decisiones comerciales, además de modelos de lenguaje a gran escala que posibilitan la interacción en lenguaje natural con sistemas de información empresarial. El Machine Learning permite que los sistemas optimicen su rendimiento gracias a la experiencia sin requerir una programación explícita (Gangadharan et al., 2024), mientras que la inteligencia artificial generativa hace posible que se generen y consulten respuestas sobre bases de datos estructuradas a través del lenguaje natural (Jiang et al., 2025).

Definición operacional:

Plataforma web compuesta por un módulo de apoyo comercial para vendedores y un módulo de análisis conversacional, alimentada con datos históricos centralizados en un DataMart extraído desde SAP HANA a

través de SAP Business One, cuyo funcionamiento y uso se evalúa mediante indicadores de desempeño y utilización del sistema.

Dimensiones e indicadores

Tabla 1

Tabla de Variable Independiente de Dimensiones e Indicadores

Dimensión	Indicador	Técnica	Instrumento
Funcionalidad del módulo de ML	Precisión del modelo de Machine Learning	Evaluación de modelos de Machine Learning	Métricas de rendimiento como F1-score, AUC-ROC
Uso del módulo de apoyo comercial	Porcentaje de consultas comerciales resueltas mediante el sistema durante la atención al cliente.	Análisis de uso del sistema	Registro de interacciones del sistema

Funcionalidad del módulo conversacional	Precisión en la generación de consultas en lenguaje natural	Evaluación de consultas generadas	Registro de consultas y resultados
Desempeño del sistema	Tiempo de respuesta del sistema	Medición de tiempos	Registro automático del sistema

Variable dependiente: Gestión comercial en Industrias Jhomeron S.A.

Definición conceptual:

La gestión comercial es un conjunto de procesos enfocados en la planificación, ejecución y supervisión de las actividades de venta de una entidad, que abarcan el servicio al cliente, la detección de oportunidades para ventas cruzadas y el acceso a información para tomar decisiones. En empresas manufactureras medianas, esta gestión depende en gran medida del conocimiento individual de los vendedores y de la disponibilidad oportuna de información comercial (Jarotschkin et al., 2025), siendo su optimización un factor determinante para la competitividad y el crecimiento empresarial (Singh et al., 2024).

Definición operacional:

Se mide mediante indicadores de desempeño comercial obtenidos a partir de registros de ventas y del uso del sistema, comparando los resultados previos y posteriores a la implementación de la solución sugerida.

Dimensiones e indicadores

Tabla 2

Tabla de Variable Dependiente de Dimensiones e Indicadores

Dimensión	Indicador	Técnica	Instrumento
Efectividad del apoyo comercial	Número de productos adicionales es aceptado s por transacción durante la atención al cliente	Análisis de datos de ventas	Reportes del sistema generados desde el DataMart
Acceso a información para la toma	Tiempo promedio de respuesta	Medición comparativa	Bitácora de consultas

de	a		del
decisiones	consultas		sistema
	comercial		
	es		
Análisis del	Frecuenci	Análisis	Base de
comportamie	a de	estadístic	datos
nto de	compra	o	transaccio
clientes	por	descriptiv	nal
	cliente y	o	
	categoría		
	de		
	producto		

CAPÍTULO IV METODOLOGÍA

4.1. Diseño Metodológico

La presente investigación adopta un diseño cuasiexperimental, dado que se trabaja con grupos naturalmente conformados sin asignación aleatoria. Este diseño permite evaluar el impacto del sistema propuesto sobre los indicadores de gestión comercial mediante la comparación entre un grupo experimental y un grupo de control durante un período definido de validación, siendo adecuado cuando los grupos ya existen por razones propias de la organización estudiada.

El grupo experimental está conformado por los siete vendedores que operan en provincias, quienes utilizarán el sistema durante el período de validación. Este grupo fue seleccionado porque representa la situación

más crítica dentro de la empresa: al encontrarse alejados de la sede central, cuentan únicamente con un sitio web y catálogos físicos y digitales compartidos por WhatsApp como recursos de consulta, herramientas que no les permiten acceder a información personalizada del cliente ni a la escala de precios por volumen vigente. Su contacto presencial con la jefa de ventas o gerencia ocurre aproximadamente una vez al mes, cuando se trasladan a Lima por tres a cinco días. Todas sus consultas sobre precios, productos y condiciones comerciales se realizan mediante llamadas telefónicas o mensajes por WhatsApp, canales que presentan restricciones frecuentes como línea ocupada o la imposibilidad de realizar una consulta mientras el cliente está presente, lo que obliga a interrumpir la atención al cliente o, en el peor caso, perder la oportunidad de venta por falta de información oportuna.

El grupo de control está conformado por los diez vendedores que operan en Lima, quienes continúan desarrollando sus actividades comerciales mediante el proceso actual de consulta manual, dado que su proximidad a la empresa les permite acceder a la información de forma presencial.

El esquema del diseño es el siguiente:

GE (Provincias, n=7): O1 → X → O2

GC (Lima, n=10): O3 → O4

Donde GE es el grupo experimental, GC es el grupo de control, O1 y O3 son las mediciones iniciales de los indicadores en cada grupo antes de la intervención, X corresponde a la implementación del sistema basado en Machine Learning e inteligencia artificial generativa, y O2 y O4 son las mediciones finales en cada grupo tras el período de validación.

Se utilizará la metodología ágil Scrum para implementar el sistema. La metodología fue elegida debido a que el sistema está compuesto por módulos claramente diferenciados que pueden desarrollarse de forma iterativa, el período de desarrollo es acotado y requiere flexibilidad para ajustar prioridades, y la validación con los vendedores de provincias requiere revisiones periódicas para incorporar ajustes según su experiencia de uso. El desarrollo se organizará en sprints sucesivos, abarcando las etapas de preparación de datos, entrenamiento del modelo de Machine Learning, desarrollo del módulo de inteligencia artificial generativa e implementación de la interfaz web con validación final.

4.2. Técnicas de recolección de datos

Se emplean dos fuentes de datos complementarias para validar y desarrollar el sistema.

La primera fuente son los datos históricos de ventas de Industrias Jhomeron S.A., los cuales son extraídos automáticamente desde SAP HANA, la base de datos subyacente de SAP Business One, mediante procedimientos almacenados ejecutados a través de un proceso ETL implementado con Spring Batch de forma semanal, y centralizados en el DataMart propio del sistema implementado en PostgreSQL. Estos datos contienen registros de ventas por cliente, producto, fecha, monto, precio de venta aplicado, zona geográfica y vendedor encargado, y constituyen el insumo principal para el entrenamiento de los modelos de Machine Learning y la base de datos sobre la que opera el módulo de inteligencia artificial generativa. Como segunda fuente de datos de configuración se utiliza el archivo Excel de precios gestionado por la jefa de ventas, el cual

contiene la lista oficial de precios por unidad y por volumen de cada producto, y es cargado al sistema como tabla de referencia actualizable. Es relevante aclarar que el sistema no funciona en tiempo real, ya que los patrones de conducta de compra de los consumidores no cambian cada día, sino en intervalos más largos, lo que hace del procesamiento por lotes un esquema técnicamente adecuado para el contexto de la empresa.

La segunda fuente son los registros de uso del sistema durante el período de validación. Para el módulo de apoyo comercial, se registrará el número de consultas realizadas y los análisis de historial solicitados por los vendedores del grupo experimental. Para el módulo de análisis conversacional, se registrarán las consultas formuladas por la gerencia, el tiempo de respuesta y la precisión de las consultas generadas. Los instrumentos incluyen fichas de registro de uso del sistema y bitácoras de consultas generadas automáticamente. Para el grupo de control, se registrará el tiempo que los vendedores de Lima emplean en hacer consultas a la jefa de ventas o gerencia por teléfono o WhatsApp para obtener información sobre precios, productos y condiciones comerciales.

4.3. Técnicas estadísticas para el procesamiento de la información

El modelo de Machine Learning será planteado como un problema supervisado de clasificación orientado a estimar la probabilidad de adquisición de productos complementarios por parte del cliente utilizando información derivada del historial transaccional. El F1-score, que combina la precisión y el recall en una sola medida, se empleará como métrica principal para la evaluación del modelo. Este índice facilita la evaluación del balance entre las predicciones correctas y la cobertura del modelo.

Además, se utilizará el área que está debajo de la curva ROC para analizar la capacidad discriminativa del modelo, teniendo en cuenta la disparidad natural entre las transacciones con y sin productos complementarios en el DataMart histórico de Industrias Jhomeron S.A. El algoritmo que obtenga mejores métricas como Random Forest o XGBoost, será seleccionado e implementado en el módulo de apoyo comercial del sistema propuesto. La estadística descriptiva se utilizará para caracterizar el comportamiento de los indicadores en ambos grupos a fin de evaluar el efecto del sistema sobre los indicadores de gestión comercial. Se utilizará la prueba T de Student con muestras independientes y un intervalo de confianza del 95 % con el fin de establecer si las discrepancias entre el grupo experimental y el grupo de control son significativas desde el punto de vista estadístico. Debido a que la muestra es pequeña, se llevará a cabo antes la prueba de Shapiro-Wilk para validar el supuesto de normalidad.

4.4. Diseño muestral

La unidad de análisis son los vendedores activos de Industrias Jhomeron S.A. y las transacciones comerciales registradas en su sistema de planificación de recursos para empresas. La población está conformada por los 17 vendedores de la empresa distribuidos entre Lima y provincias. El grupo experimental está compuesto por los siete vendedores que operan en provincias, seleccionados por las razones descritas en la sección 4.1. Este grupo representa el segmento con mayor limitación de acceso a información durante la atención al cliente, y por tanto donde el impacto del sistema puede medirse de forma más clara y significativa. El

grupo de control está compuesto por los diez vendedores de Lima, quienes mantienen el proceso habitual de consulta durante el mismo período de validación. Los criterios de inclusión para los dos grupos son: ser un vendedor activo de Industrias Jhomerón S.A. en el momento del estudio y tener tres meses o más de antigüedad en la compañía, con el fin de asegurar que los participantes cuenten con experiencia suficiente en el proceso actual de consulta para poder evaluar el impacto del sistema. Para el entrenamiento de los modelos de aprendizaje automático se utilizará el historial completo de ventas disponible de los últimos tres años, sin restricción de tamaño muestral, con el fin de garantizar la representatividad de los patrones de compra por cliente, producto y zona geográfica.

4.5. Aspectos éticos

La investigación cumple con los principios éticos establecidos para la investigación en ingeniería de sistemas. En cuanto a la confidencialidad de los datos, toda la información comercial y transaccional de Industrias Jhomerón S.A. utilizada en la investigación será tratada con estricta reserva y empleada exclusivamente con fines académicos y de validación del sistema, previo acuerdo formal con la empresa, cuya carta de autorización se presenta en el **Anexo 10**. Los datos de clientes serán anonimizados durante el desarrollo y validación del sistema, garantizando el cumplimiento de la normativa peruana de protección de datos personales establecida en la Ley N.º 29733.


Respecto al consentimiento informado, los vendedores que participen en las pruebas de validación serán informados del propósito de la

investigación y de las actividades que se realizarán con los registros de uso del sistema, prestando su consentimiento de forma voluntaria. La investigación no implica riesgos para los participantes ni interrupciones en la operación de la empresa, dado que el sistema actúa como herramienta de apoyo y no reemplaza las decisiones humanas. El acceso a los datos de la empresa se limita estrictamente a lo necesario para el entrenamiento y validación del sistema, sin que el equipo de investigación retenga información sensible más allá del período de desarrollo del proyecto.

CRONOGRAMA

Para la elaboración del cronograma del proyecto se utilizó la herramienta Jira, la cual permitió realizar la planificación de tareas, la asignación de actividades y el seguimiento continuo del avance del proyecto. Asimismo, se empleó el cronograma tipo Diagrama de Gantt integrado en la plataforma, facilitando la visualización de la duración de cada actividad, las dependencias entre tareas y la trazabilidad del progreso del proyecto a lo largo del tiempo, como se muestra en la **Figura 1**. El detalle de las tareas por sprint se presenta en el **Anexo 11**.

Figura 1
Diagrama de Gantt



Nota: El diagrama de Gantt integra el periodo de 1 de marzo a 30 de junio del 2026.

FUENTES DE INFORMACIÓN

Boustani, N., Emrouznejad, A., Gholami, R., Despic, O., & Ioannou, A. (2024).

Improving the predictive accuracy of the cross-selling of consumer loans using deep learning networks. *Annals of Operations Research*, 339(1), 613-630. <https://doi.org/10.1007/s10479-023-05209-5>

Condori, P. P. C. (2023). Segmentación de mercado: Machine Learning en marketing en contextos de covid-19. *Industrial Data*, 26(1), 275-301. <https://doi.org/10.15381/idata.v26i1.23623>

Fang, L., Yuan, Z., Zhang, K., Donati, D., & Sarvary, M. (2026). *Generative AI and Firm Productivity: Field Experiments in Online Retail*. <https://doi.org/10.48550/arXiv.2510.12049>

Flores Poemape, C. G., & Flores Sulca, S. (2025). Machine learning para la gestión de ventas en una empresa del sector tecnológico, Lima, 2025. *Repositorio Institucional - UCV*. <https://repositorio.ucv.edu.pe/handle/20.500.12692/179240>

Gangadharan, K., Malathi, K., Purandaran, A., Subramanian, B., Jeyaraj, R., & Jung, S. K. (2024). From Data to Decisions: The Transformational Power of Machine Learning in Business Recommendations. *arXiv.Org*. <https://doi.org/10.1109/ACCESS.2025.3532697>

Jarotschkin, V., Soyko, M. W., & Chaker, N. N. (2025). Artificial intelligence in sales research: Identifying emergent themes and looking forward. *Journal of Business Research*, 198, 115383. <https://doi.org/10.1016/j.jbusres.2025.115383>

Jiang, J., Xie, H., Shen, S., Shen, Y., Zhang, Z., Lei, M., Zheng, Y., Li, Y., Li, C., Huang, D., Wu, Y., Zhang, W., Yang, X., Cui, B., & Chen, P. (2025).

SiriusBI: A Comprehensive LLM-Powered Solution for Data Analytics in Business Intelligence. <https://doi.org/10.48550/arXiv.2411.06102>

Le Dinh, T., Vu, M.-C., & Tran, G. T. C. (2025). Artificial Intelligence in SMEs: Enhancing Business Functions Through Technologies and Applications. *Information*, 16(5), 415. <https://doi.org/10.3390/info16050415>

Liang, S., & Zhang, Y. (2025). Generative Recommendation: A Survey of Models, Systems, and Industrial Advances. *TechRxiv*, (1220). <https://doi.org/10.36227/techrxiv.176523089.94266134/v2>

Liu, X., Shen, S., Li, B., Ma, P., Jiang, R., Zhang, Y., Fan, J., Li, G., Tang, N., & Luo, Y. (2025). A Survey of Text-to-SQL in the Era of LLMs: Where are we, and where are we going? <https://doi.org/10.48550/arXiv.2408.05109>

Loukili, M., Messaoudi, F., Ghazi, M. E., & Azirar, H. (2024). Predicting Future Sales: A Machine Learning Algorithm Showdown. *Artificial Intelligence, Data Science and Applications*, 26-31. https://doi.org/10.1007/978-3-031-48465-0_4

Mhaskey, S. V. (2024). Integration of Artificial Intelligence (AI) in Enterprise Resource Planning (ERP) Systems: Opportunities, Challenges, and Implications. *ResearchGate*. <https://doi.org/10.22362/ijcert/2024/v11/i12/v11i1201>

Mirkovski, K., Williams, P., Liu, L., Liu, H., & Indulska, M. (2025). An AI-Assisted Framework for Improving Innovativeness in Small Businesses: A Human–AI Collaboration Perspective. *Information Systems Journal*, 35(6), 1603-1629. <https://doi.org/10.1111/isj.12597>

Ou, T.-Y., Chen, C.-H., & Tsai, W.-L. (2025). Establishing a Dynamic Recommendation System for E-commerce by Integrating Online

Reviews, Product Feature Expansion, and Deep Learning. *Applied Artificial Intelligence*, 39(1), 2463723.

<https://doi.org/10.1080/08839514.2025.2463723>

Peng, S., Swiatek, W., Gao, A., Cullivan, P., & Chang, H. (2024). *AI Revolution on Chat Bot: Evidence from a Randomized Controlled Experiment*.

<https://doi.org/10.48550/arXiv.2401.10956>

Poniszewska-Maranda, A., Pakula, M., & Borowska, B. (2025).

Recommendation systems in e-commerce applications with machine learning methods. <https://doi.org/10.48550/arXiv.2506.17287>

Singh, M., Pasricha, R., Singh, N., Kondapalli, R. P., R, M., R, K., & Boué, L. (2024). A case study of Generative AI in MSX Sales Copilot: Improving seller productivity with a real-time question-answering system for content recommendation. *arXiv.Org*.

<https://doi.org/https://doi.org/10.48550/arXiv.2401.04732>

Suarez Romero, A. C. (2024). *Modelo Deep Learning para mejorar la predicción de las ventas en la Empresa San Fernando S.A.C., Lima, 2023*. <https://hdl.handle.net/20.500.13084/8850>


Xu, K., Zhou, H., Zheng, H., Zhu, M., & Xin, Q. (2024). Intelligent Classification and Personalized Recommendation of E-commerce Products Based on Machine Learning. *arXiv.Org*.

<https://doi.org/https://doi.org/10.48550/arXiv.2403.19345>

ANEXOS

Anexo 1


Diagrama AS IS del Módulo de Vendedores



Nota: Elaboración propia.

Anexo 2

Diagrama AS IS del Módulo de Gerencia



Nota: Elaboración propia.

Anexo 3

Análisis Económico y Financiero del Sistema Propuesto

Sección A: Costos operativos mensuales (OPEX)

Componente	Tecnología / Servicio	Costo Mensual (S/.)
Frontend Web	Cloudflare Pages	0
Backend API	Spring Boot (On-Premise — Coolify)	0

Procesamiento ETL	Spring Batch (On-Premise — Coolify)	0
Motor Predictivo	FastAPI + XGBoost (On-Premise)	0
Monitoreo	Prometheus + Grafana (On-Premise)	0
Base de Datos	PostgreSQL (Fly.io)	15
Hosting de Aplicación	Fly.io	15
Almacenamiento de Datos	AWS S3	15
IA Generativa	Amazon Bedrock — Claude 3 Haiku	15
Respaldos y contingencia	Almacenamiento externo	20
Margen de crecimiento operativo	Reserva presupuestal	20
TOTAL OPEX MENSUAL ESTIMADO		S/. 100

Nota: Las herramientas desplegadas On-Premise no generan costo adicional al utilizar la infraestructura existente de Industrias Jhomeron S.A. Tipo de cambio referencial: 1 USD = S/. 3.50. Elaboración propia.

Sección B: Análisis de viabilidad financiera

Supuestos del modelo

Parámetro	Valor	Fuente
Meta de ventas mensual por vendedor (GE)	S/. 80,000	Información proporcionada por Industrias Jhomerón S.A.
Ticket promedio por pedido	S/. 500	Estimación basada en cartera mixta de clientes
Pedidos estimados por vendedor al mes	160 pedidos	Meta mensual / ticket promedio
Tasa de oportunidades perdidas por falta de información	3%	Estimación conservadora — jefa de ventas Jhomerón S.A.
Pedidos recuperables por vendedor al mes	5 pedidos	$160 \times 3\%$
Vendedores del grupo experimental	7	Fuerza de ventas de provincias
Tasa de descuento mensual (COK referencial)	1%	Tasa referencial para proyecto académico
Horizonte de evaluación	4 meses	Período académico

Nota: *Elaboración propia.*

Escenario	Vendedores	Beneficio mensual	VAN (4 meses)
-----------	------------	-------------------	---------------

Validación — grupo experimental	7	S/. 17,500	S/. 67,894
Producción completa	17	S/. 42,500	S/. 164,877

Nota: El escenario de validación considera únicamente los siete vendedores del grupo experimental durante el período del estudio. El escenario de producción completa proyecta el impacto sobre los diecisiete vendedores activos de Industrias Jhomerón S.A. en operación real del sistema.

Flujo de caja mensual estimado

Concepto	Mes 0	Mes 1	Mes 2	Mes 3	Mes 4
Inversión inicial	S/. 0	—	—	—	—
Costo operativo del sistema	—	-S/. 100	-S/. 100	-S/. 100	-S/. 100
Beneficio estimado por ventas recuperadas	—	+S/. 17,500	+S/. 17,500	+S/. 17,500	+S/. 17,500
Flujo neto mensual	S/. 0	S/. 17,400	S/. 17,400	S/. 17,400	S/. 17,400

Nota: Beneficio mensual = 5 pedidos recuperados × S/. 500 × 7 vendedores = S/. 17,500, Inversión inicial = S/. 0 dado que el desarrollo es realizado por el equipo investigador como parte del proyecto académico.

Cálculo del VAN

$$\text{VAN} = \text{S/. } 17,400/(1.01)^1 + \text{S/. } 17,400/(1.01)^2 + \text{S/. } 17,400/(1.01)^3 + \text{S/. } 17,400/(1.01)^4$$

$$\text{VAN} = \text{S/. } 17,228 + \text{S/. } 17,057 + \text{S/. } 16,888 + \text{S/. } 16,721$$

$$\text{VAN} = \text{S/. } 67,894$$


Indicadores financieros

Indicador	Resultado	Interpretación
VAN (COK 1% mensual, 4 meses)	S/. 67,894	Mayor a 0, proyecto financieramente viable
TIR mensual	> 100%	Mayor al COK, rentable desde el primer mes de operación
Período de recuperación	< 1 día	El beneficio del primer mes supera el costo total del período
Costo operativo mensual	S/. 100	Representa el 0.57% del beneficio mensual estimado

Nota: *Elaboración propia.*

Anexo 4


Arquitectura de Solución



Nota: *Elaboración propia.*

Anexo 5


Diseño del Datamart para el Sistema Propuesto



Nota: *Elaboración propia.*

Anexo 6


Diagrama TO BE del Módulo de Vendedores



Nota: *Elaboración propia.*

Anexo 7

Diagrama TO BE del Módulo de Gerencia



Nota: *Elaboración propia.*

Anexo 8

Artículo de Investigación

Análisis de sistemas basados en Machine Learning e inteligencia artificial generativa para la optimización de la gestión de ventas

[Analysis of systems based on Machine Learning and generative artificial intelligence for sales management optimization]

Juan M. Torvisco Ríos

Jean Pierre A. Lobatón Ochoa

1 Facultad de Ingeniería y Arquitectura, Universidad San Martín de Porres, Lima, Perú

Autores de correspondencia:

juan_torvisco@usmp.pe

jean_lobaton@usmp.pe

Resumen: El Machine Learning y la inteligencia artificial generativa han emergido como tecnologías transformadoras en la gestión de ventas, permitiendo que las organizaciones conviertan grandes volúmenes de datos transaccionales en decisiones comerciales más precisas y oportunas. Este estudio tuvo como objetivo analizar cómo los sistemas basados en Machine Learning e inteligencia artificial generativa optimizan la gestión de ventas en comparación con los enfoques tradicionales, considerando sus resultados, limitaciones y contextos de aplicación. Se aplicó un enfoque mixto que integró una revisión sistemática de investigaciones recientes y un análisis cuantitativo orientado a identificar las principales tendencias, autores y países con mayor producción académica en el área. La revisión de 33 estudios publicados entre 2021 y 2026 evidenció que los algoritmos de aprendizaje supervisado como Random Forest y XGBoost presentan un desempeño superior en la predicción y recomendación de ventas en comparación con los modelos estadísticos tradicionales, con mejoras documentadas en eficiencia comercial de hasta 16.3 % en experimentos de campo a gran escala. Asimismo, los sistemas de consulta en lenguaje natural basados en grandes modelos de lenguaje alcanzan precisiones superiores al 93% en la generación de consultas sobre bases de datos empresariales, reduciendo el tiempo de acceso a la información de minutos a segundos. Los resultados muestran que la integración de estas tecnologías mejora la personalización de la oferta comercial, incrementa las tasas de venta cruzada y optimiza la toma de decisiones en entornos distribuidos. Sin embargo, persisten limitaciones relacionadas con la calidad de los datos, los costos de implementación y la resistencia organizacional al cambio. En conclusión, el Machine Learning y la inteligencia artificial generativa representan un avance significativo para la gestión de ventas y muestran un potencial prometedor para su aplicación en empresas manufactureras medianas con fuerzas de ventas distribuidas geográficamente.

Palabras clave: *Machine Learning; inteligencia artificial generativa; gestión de ventas; sistemas de recomendación; pronóstico de ventas; procesamiento de lenguaje natural.*

Abstract: Machine Learning and generative artificial intelligence have emerged as transformative technologies in sales management, enabling organizations to convert large volumes of transactional data into more accurate and timely commercial decisions. This study aimed to analyze how systems based on Machine Learning and generative artificial intelligence optimize sales management compared to traditional approaches, considering their outcomes, limitations, and application contexts. A mixed approach was applied, integrating a systematic review of recent research and a scientometric analysis designed to identify the main trends, authors, and countries with the highest academic production in the field. The review of 33 studies published between 2020 and 2026 showed that supervised learning algorithms such as Random Forest and XGBoost outperform traditional statistical models in sales prediction and recommendation tasks, with documented improvements in commercial efficiency of up to 16.3 % in large-scale field experiments. Additionally, natural language query systems based on large language models achieve accuracy rates above 93 % in generating queries over enterprise databases, reducing information access time from minutes to seconds. Results show that integrating these technologies improves commercial offer personalization, increases cross-selling rates, and optimizes decision-making in distributed environments. However, limitations persist regarding data quality, implementation costs, and organizational resistance to change. In conclusion, Machine Learning and generative artificial intelligence represent a significant advancement for sales management and show promising potential for application in medium-sized manufacturing companies with geographically distributed sales forces.

Keywords: *Machine Learning; generative artificial intelligence; sales management; recommendation systems; sales forecasting; natural language processing*

INTRODUCCIÓN

El Machine Learning y la inteligencia artificial generativa se han consolidado como herramientas fundamentales en la gestión comercial moderna, transformando la forma en que las organizaciones procesan datos transaccionales para mejorar su desempeño de ventas. La adopción acelerada de estas tecnologías ha generado una producción científica creciente que documenta sus aplicaciones, beneficios y limitaciones en contextos empresariales de distinta escala y sector. Sin embargo, la evidencia sobre su efectividad en la optimización integral de la gestión de ventas, que abarca tanto la recomendación personalizada de productos como el acceso conversacional a información analítica, continúa siendo fragmentada y dispersa en la literatura (Saptadi et al., 2026).

La gestión de ventas en empresas medianas enfrenta una limitación estructural: los datos históricos de transacciones existen en los sistemas de información, pero no se transforman de manera

efectiva en conocimiento operativo para los equipos comerciales. Estudios recientes han confirmado que la subutilización de datos comerciales genera pérdidas directas de oportunidades de venta, mientras que las organizaciones que logran capitalizar su información histórica mediante inteligencia artificial incrementan sus ingresos de forma medible (Fang et al., 2026). Esta brecha entre disponibilidad de datos y su aprovechamiento efectivo limita la capacidad de los vendedores para personalizar su oferta y dificulta el análisis ágil de la información por parte de los equipos directivos (Jarotschkin et al., 2025).

En el ámbito de los sistemas de recomendación comercial, la literatura muestra que el Machine Learning permite identificar patrones de comportamiento de compra en grandes volúmenes de datos transaccionales, generando sugerencias de productos con alta probabilidad de adquisición (Gangadharan et al., 2024). Los algoritmos de conjunto como Random Forest y XGBoost han demostrado un desempeño superior al predecir ventas futuras, superando a modelos estadísticos tradicionales en precisión y capacidad de generalización (Loukili et al., 2024). En el contexto de empresas peruanas, investigaciones recientes documentan mejoras estadísticamente significativas en la eficiencia comercial al aplicar estos algoritmos sobre datos históricos de ventas (Flores Poemape y Flores Sulca, 2025), así como resultados confiables en predicción de ventas mediante modelos de aprendizaje profundo (Suárez Romero, 2024).

Por otro lado, los sistemas de inteligencia artificial generativa basados en grandes modelos de lenguaje han permitido el desarrollo de interfaces conversacionales capaces de traducir preguntas en lenguaje cotidiano en consultas ejecutables sobre bases de datos estructuradas, eliminando la necesidad de conocimientos técnicos para acceder a la información analítica (Liu et al., 2025). Investigaciones recientes demuestran que estos sistemas alcanzan precisiones superiores al 93 % en la generación de consultas sobre bases de datos empresariales complejas, con reducciones del tiempo de acceso a la información de minutos a segundos (Jiang et al., 2025). Asimismo, la integración de grandes modelos de lenguaje en sistemas de asistencia a vendedores en tiempo real ha sido validada en entornos de producción reales con impacto medible en la productividad diaria (Singh et al., 2024).

La presente revisión plantea la siguiente pregunta de investigación:

¿Cómo los sistemas basados en Machine Learning e inteligencia artificial generativa optimizan la gestión de ventas en comparación con los enfoques tradicionales, en términos de resultados, efectividad y limitaciones de aplicación?

Para abordar esta cuestión, se analizan los principales hallazgos de 33 estudios seleccionados mediante el protocolo de revisión sistemática con directrices de Elementos de Informe Preferidos para Revisiones Sistemáticas y Metaanálisis. Los estudios revisados evidencian que los sistemas de

recomendación basados en Machine Learning contribuyen de forma significativa a las ventas y a la ventaja competitiva de las organizaciones (Gangadharan et al., 2024). La segmentación de clientes mediante técnicas de agrupamiento ha demostrado que el Machine Learning permite identificar patrones de comportamiento de compra diferenciados y tomar decisiones comerciales más precisas y personalizadas (Chambi Condori, 2023). A su vez, los sistemas de recomendación en comercio electrónico han mejorado su eficiencia y personalización gracias a la integración de métodos de Machine Learning, con impacto directo en la retención de clientes y el incremento de ventas (Poniszewska-Maranda et al., 2025).

Los experimentos de campo a gran escala con millones de usuarios documentan que la adopción de inteligencia artificial generativa en procesos comerciales incrementa las ventas entre 0 y 16.3 %, con mejoras directas en la productividad total de los equipos (Fang et al., 2026). En el ámbito de la predicción de demanda, los modelos de aprendizaje automático y profundo han demostrado superar consistentemente a los enfoques de pronóstico convencionales al capturar relaciones no lineales y patrones estacionales complejos en los datos de ventas (Douaioui et al., 2024). La investigación sobre inteligencia artificial en ventas identifica que los vendedores con apoyo tecnológico tienen 3.7 veces más probabilidad de alcanzar sus metas comerciales (Jarotschkin et al., 2025), lo que refleja el impacto sustancial de estas herramientas en la productividad individual.

El resto de este artículo procede en cinco secciones consecutivas. La sección 2 describe la metodología de revisión sistemática y el análisis cienciométrico empleados. La sección 3 presenta los resultados del análisis cienciométrico y la síntesis de los estudios incluidos. La sección 4 expone la discusión, describiendo las convergencias, divergencias y limitaciones identificadas en la literatura. La sección 5 presenta las conclusiones generales de la revisión y las oportunidades para futuras investigaciones.


METODOLOGÍA

La metodología de este estudio adoptó un enfoque mixto, integrando una revisión sistemática estructurada y un análisis cienciométrico. La revisión sistemática se centró en el análisis comparativo de los modelos de Machine Learning e inteligencia artificial generativa más utilizados en la gestión de ventas, con énfasis en sistemas de recomendación de productos, pronóstico de demanda y consulta de información comercial en lenguaje natural. Por su parte, el análisis cienciométrico permitió obtener una visión general de la producción científica reciente sobre el uso de estas tecnologías en entornos comerciales, identificando tendencias de publicación, autores e instituciones más influyentes (Saptadi et al., 2026).

En los estudios revisados se observa el uso sistemático de algoritmos de aprendizaje supervisado como Random Forest, XGBoost y redes neuronales para la predicción de ventas y la recomendación personalizada de productos (Loukili et al., 2024), así como la discusión de arquitecturas basadas en grandes modelos de lenguaje para la traducción de consultas en lenguaje natural a operaciones estructuradas sobre bases de datos empresariales (Jiang et al., 2025). Asimismo, se identificaron enfoques híbridos que combinan filtrado colaborativo y filtrado basado en contenido para mejorar la precisión de las recomendaciones en contextos donde los patrones de compra no son estáticos (Gangadharan et al., 2024).

El proceso metodológico se estructuró siguiendo el marco PICO, que orientó la formulación de la pregunta de investigación y la selección de las variables principales: Machine Learning e inteligencia artificial generativa como variable de intervención, gestión de ventas como variable de resultado, y enfoques tradicionales de gestión comercial como comparador. Asimismo, se aplicaron las directrices PRISMA como se muestra en la **Figura 1** y el protocolo OSF para la planificación, búsqueda, selección y análisis de la evidencia científica, como se detalla en la Tabla 1. Se consultaron las bases de datos Scopus, IEEE Xplore, ACM Digital Library, Google Scholar y arXiv, en un período comprendido entre 2021 y 2026. Se identificaron 33 artículos, de los cuales cumplieron los criterios de inclusión, estudios con metodología explícita, resultados cuantificables y relación directa con la gestión de ventas o sistemas de recomendación comercial. Los registros fueron organizados en Zotero, y el análisis cienciométrico se efectuó en Google Colab utilizando Python para procesar la co-ocurrencia de palabras clave, publicaciones por autor y distribución geográfica de la producción científica.

Figura 1: Diagrama de Flujo de Prisma



Nota: Elaboración propia.

TABLA 1: Resumen de la Revisión

Planificación	Revisión de Literatura Narrativa	Análisis de sistemas basados en Machine Learning e inteligencia artificial generativa para la optimización de la gestión de ventas	Artículos, libros, tesis	Google Scholar, bases de datos
	Definir Pregunta PICO	¿Cómo los sistemas basados en Machine Learning e inteligencia artificial generativa optimizan la gestión de ventas en comparación con los enfoques tradicionales, en términos de resultados, efectividad y limitaciones de aplicación?	Marco PICO	Word, Excel
	Identificación de GAP y subpreguntas	¿Cuál es el desempeño de los algoritmos de Machine Learning en la predicción y recomendación de ventas? ¿Cómo la inteligencia artificial generativa mejora el acceso a información comercial en lenguaje natural?	Revisión narrativa	Word
	Refinamiento de preguntas y criterios	Inclusión: estudios 2020-2026, idiomas español e inglés, metodología explícita, resultados cuantificables, relación directa con ventas o recomendación. Exclusión: sin revisión por pares, sin metodología documentada, sin relación con gestión de ventas.	Protocolo OSF	Word, Excel
Búsqueda	Identificación y validación de palabras clave	Machine Learning, inteligencia artificial generativa, gestión de ventas, sistemas de recomendación, pronóstico de ventas, venta cruzada, grandes modelos de lenguaje y sus equivalentes en inglés	Literatura previa	Word
	Ejecución de cadenas por base de datos	Cadenas de búsqueda ejecutadas en cada base de datos seleccionada	Scopus, IEEE Xplore, ACM, Google Scholar, arXiv	Excel, Zotero
	Selección de bases de datos	Scopus, IEEE Xplore, ACM Digital Library, Google Scholar, arXiv	Ficha de investigador	Excel, Zotero
Selección y evaluación	Identificación de estudios	80 artículos identificados en total	Conjuntos de datos iniciales	Excel, Zotero
	Eliminación de duplicados	70 documentos restantes importados a Zotero	Protocolo PRISMA	Excel
	Criba por título y resumen	37 artículos excluidos por criterios de relevancia y metodología	Revisión narrativa	Word
	Evaluación de calidad	33 artículos incluidos en la síntesis final	Revisión crítica	Excel, Word
Bibliometría	Importación y refinamiento de datos	Resultados preliminares de bibliometría: co-ocurrencia de palabras clave, redes de autoría, países y fuentes	Protocolo bibliométrico	Python, Colab

	Identificación de clústeres y visualización	Dataset ordenado y gráficos de tendencias temáticas	Bibliometría, redes	Python, Colab, Excel	Google
Síntesis	Extracción y síntesis de datos	Resultados organizados por tema: recomendación, pronóstico, consulta en lenguaje natural	Revisión narrativa sistematizada	Word, Excel	
Redacción	Elaboración del informe	Artículo final siguiendo directrices PRISMA	PRISMA, PICO	Word	
	Justificación	Compara el desempeño de sistemas basados en Machine Learning e inteligencia artificial generativa para la gestión de ventas frente a enfoques tradicionales	PRISMA, PICO	Word	

Nota: *Elaboración propia.*

Selección de la base de datos y recopilación de datos

Las bases de datos seleccionadas para esta investigación fueron Scopus, IEEE Xplore, ACM Digital Library, Google Scholar y arXiv, debido a su cobertura integral de literatura científica relacionada con el Machine Learning, la inteligencia artificial generativa y la gestión de ventas. Estas plataformas ofrecen acceso a publicaciones revisadas por pares y garantizan la calidad y fiabilidad de las fuentes utilizadas. La selección se basó en su relevancia académica y diversidad temática, abarcando los campos de la ingeniería de sistemas, la informática empresarial y la gestión comercial. Antes de ejecutar la búsqueda definitiva, se realizó una revisión preliminar para verificar la pertinencia de las palabras clave y ajustar las estrategias de búsqueda a los criterios del estudio. Este proceso se alinea con las prácticas de revisión bibliométrica descritas en estudios previos sobre Machine Learning aplicado a la predicción de ventas (Santadi et al., 2026).

Estrategia de selección de palabras clave, criterios de inclusión y exclusión

Los datos bibliográficos se recopilaron de las bases de datos seleccionadas mediante palabras clave definidas en función del alcance de la investigación. Todas las bases de datos se utilizaron de manera consistente por su cobertura sobre Machine Learning, inteligencia artificial generativa y gestión de ventas. Antes de realizar las búsquedas finales, se efectuó una revisión preliminar para comprobar la relevancia de las palabras clave y asegurar la calidad de los resultados. Se identificaron 33 artículos publicados entre 2021 y 2026, de los cuales 33 cumplieron los criterios de inclusión definidos por su pertinencia metodológica y científica.

Los criterios de inclusión contemplaron estudios que aborden el uso de Machine Learning o inteligencia artificial generativa en contextos de ventas, gestión comercial o recomendación de productos; publicados entre 2020 y 2026; escritos en español o inglés; con metodología explícita y resultados cuantificables. En concordancia con revisiones previas, se priorizaron los trabajos que documentan aplicaciones reales de estas tecnologías en entornos empresariales (Flores Poemape y Flores Sulca, 2025). Se excluyeron publicaciones sin revisión por pares o sin metodología

documentada, estudios sin relación directa con gestión de ventas, y trabajos duplicados en las distintas bases de datos consultadas. Los textos seleccionados fueron organizados en Zotero para su clasificación y análisis bibliográfico.

Elección de herramientas informáticas para el análisis y revisión crítica


Se realizó un análisis cienciométrico a partir de los datos extraídos de las bases de datos seleccionadas, empleando el lenguaje de programación Python dentro del entorno Google Colab, que facilitó la ejecución de rutinas para el mapeo de la estructura, la segmentación por palabras clave y la agrupación temática de la literatura científica sobre Machine Learning e inteligencia artificial generativa aplicados a la gestión de ventas. Las bibliotecas Pandas y Matplotlib se utilizaron para organizar y representar la información en formato tabular y gráfico, respectivamente, permitiendo un tratamiento reproducible de los datos. El proceso incluyó la identificación de co-ocurrencia de palabras clave, colaboración entre autores, distribución geográfica de publicaciones y análisis de revistas científicas más citadas (Douaioui et al., 2024). Los resultados fueron sintetizados y contrastados con trabajos previos en los que se aplicaron sistemas de Machine Learning e inteligencia artificial generativa a procesos de ventas, evaluando su rendimiento en términos de precisión, eficiencia y adopción organizacional. Esto permitió un análisis comparativo de los enfoques actuales y la identificación de brechas en la literatura (Jarotschkin et al., 2025).

Etapas adoptadas en la revisión

En la revisión sistemática se siguió un riguroso protocolo de 10 pasos basado en la metodología OSF, que abarca desde la especificación de la pregunta de investigación y la selección de fuentes de información hasta el establecimiento de una estrategia de búsqueda y criterios de elegibilidad. Posteriormente se ejecutó el proceso de selección de estudios, se extrajeron y sintetizaron los datos pertinentes considerando el riesgo de sesgo, para finalmente presentar hallazgos claros e informativos como se muestra en la **Figura 2**.

De los 33 artículos identificados inicialmente, se eliminaron los duplicados, quedando 33 documentos para evaluación por título y resumen. Estos estudios cubren el periodo 2021 a 2026 y provienen de Scopus, IEEE Xplore, ACM Digital Library, Google Scholar y arXiv, representando contextos de aplicación en empresas de distintos tamaños, sectores y regiones geográficas, incluyendo estudios realizados en el contexto latinoamericano.


Figura 2: Pasos de la Revisión Literaria



Nota: *Elaboración propia.*

Anexo 9

Diseño de Interfaces del Sistema Propuesto





Nota: Elaboración propia.

Anexo 10

Carta de Autorización de Industrias Jhomeron S.A.

Lima, 29 abril de 2026

Asunto:

Autorización para el desarrollo de proyecto de investigación académica

Estimados señores:

Por medio de la presente, yo, LLANOS TORRES DANITZA en mi calidad de Jefa de Sistemas de INDUSTRIAS JHOMERON S.A., me dirijo a ustedes para hacer constar lo siguiente:

Que la empresa INDUSTRIAS JHOMERON S.A. autoriza a los señores JUAN MARCIAL TORVISCO RIOS y JEAN PIERRE ANTHONY LOBATON OCHOA, estudiantes de la Escuela de Ingeniería de Computación y Sistemas de la Universidad de San Martín de Porres, con código de estudiante N.º 71225372 y N.º 76605665 respectivamente, para llevar a cabo el proyecto de investigación titulado:

“SISTEMA BASADO EN MACHINE LEARNING E IA GENERATIVA PARA OPTIMIZAR LA GESTIÓN COMERCIAL EN INDUSTRIAS JHOMERON S.A.”

dicho proyecto es asesorado por el Dr. Jorge Martín Figueroa Revilla y se desarrolla en el marco de la asignatura Proyecto Final de Ingeniería de Computación y Sistemas, período académico 2026-I.

La presente autorización comprende:

- a) El acceso a datos históricos de ventas registrados en el sistema SAP Business One de la empresa, los cuales serán utilizados exclusivamente para el entrenamiento y validación del sistema propuesto.
- b) La participación voluntaria de los vendedores activos de la empresa en las pruebas de validación del sistema, previa información sobre el propósito de la investigación.
- c) El uso de la denominación e información general de la empresa en el documento académico correspondiente.

La información proporcionada será tratada con estricta confidencialidad, empleada únicamente con fines académicos y de validación, y los datos de clientes serán anonimizados en todo momento, en cumplimiento de la Ley N.º 29733, Ley de Protección de Datos Personales del Perú. La presente autorización no implica ningún compromiso económico para la empresa.

Sin otro particular, me despido cordialmente.

Firma: 
DNI: 75471720

Anexo 11

Lista de Tareas - Sprint 1

Jean Pierre Lobaton Ochoa (11 tareas)

ID	Tarea	Vencimiento	Tiempo
SCRUM-1	Redacción: Capítulo I Planteamiento del Problema	2026-03-31	3.0 días (24h)
SCRUM-4	Redacción: Capítulo III Propuesta del Sistema	2026-05-15	2.0 días (16h)
SCRUM-5	Redacción: Capítulo IV Metodología	2026-05-26	2.0 días (16h)
SCRUM-6	Corrección y Consolidación del Documento	2026-06-30	2.0 días (16h)
SCRUM-36	Redacción: Descripción de la situación problemática	2026-03-07	2.0 días (16h)

SCRUM-38	Definición de Objetivos Generales y Específicos	2026-03-21	2.0 días (16h)
SCRUM-41	Redacción de Antecedentes de investigación	2026-04-14	2.0 días (16h)
SCRUM-43	Desarrollo de Bases Teóricas (LLM y SAP Business One)	2026-04-28	2.0 días (16h)
SCRUM-45	Diseño documental de la propuesta arquitectónica	2026-05-07	2.0 días (16h)
SCRUM-46	Definición de Módulos ML y LLM y variables operacionales	2026-05-15	2.0 días (16h)
SCRUM-49	Redacción de Aspectos Éticos y Cronograma	2026-05-26	2.0 días (16h)

Nota: *Elaboración propia.*

Juan Torvisco (9 tareas)

ID	Tarea	Vencimiento	Tiempo
SCRUM-2	Redacción: Capítulo II Marco Teórico	2026-04-30	2.0 días (16h)
SCRUM-3	Levantamiento de Información de la Empresa (CSV)	2026-04-15	2.0 días (16h)
SCRUM-37	Formulación del problema general y específicos	2026-03-14	2.0 días (16h)
SCRUM-39	Redacción: Justificación de la investigación e Importancia	2026-03-31	2.0 días (16h)
SCRUM-40	Revisión de literatura y selección de antecedentes	2026-04-07	2.0 días (16h)
SCRUM-42	Desarrollo de Bases Teóricas (Machine	2026-04-21	2.0 días (16h)

	Learning y Venta Cruzada)		
SCRUM-44	Definición de términos básicos	2026-04-30	2.0 días (16h)
SCRUM-47	Definición del Diseño Metodológico Cuasiexperimenta l	2026-05-19	2.0 días (16h)
SCRUM-48	Redacción de Técnicas de recolección y diseño muestral	2026-05-23	2.0 días (16h)

Nota: *Elaboración propia.*